

L'Encoder

4[^] AM

Mancini Massimiliano

Struttura della Presentazione

✓ Intro:

- Architettura Encoder, efficienza e limiti;

✓ Pro:

- Velocità (parallelizzazione), contesto bidirezionale e scalabilità;

✓ Contro:

- Memoria per testi lunghi ($O(n^2)$), ordine delle parole e complessità tecnica;

✓ Costi:

- Hardware costoso, tempi lunghi e alto impatto ambientale;

✓ Summary:

- Encoder models are fast and powerful, but require expensive hardware and high energy;

✓ Conclusioni:

- Recap finale



Analisi dei Parametri dell'Encoder nei Modelli Transformer


L'architettura dell'Encoder garantisce velocità e analisi bidirezionale tramite la parallelizzazione, migliorando con l'aumento dei dati.

Tuttavia, il calcolo quadratico limita la gestione di testi lunghi e richiede supporti esterni per l'ordine delle parole.

L'ottimizzazione è complessa e necessita di competenze tecniche elevate per bilanciare le criticità strutturali. I costi economici e temporali sono ingenti, con un forte impatto ambientale dovuto all'alto consumo energetico. In sintesi, è uno strumento potente ma estremamente oneroso e difficile da gestire correttamente.

Vantaggi

- L'architettura dell'Encoder rivoluziona il deep learning grazie all'elaborazione parallela, che accelera i calcoli analizzando sequenze intere simultaneamente. La bidirezionalità garantisce una comprensione profonda, interpretando ogni parola nel suo contesto globale. Grazie alla Self-Attention, il modello mantiene relazioni tra termini distanti, superando i limiti dei sistemi lineari. Infine, la scalabilità permette prestazioni sempre migliori all'aumentare di dati e parametri, ottimizzando velocità e memoria per un'analisi linguistica avanzata.



- **Complessità Quadratica:**

Il consumo di memoria aumenta esponenzialmente rispetto alla lunghezza del testo; sequenze molto lunghe possono saturare rapidamente la RAM.

- **Assenza di Ordine Intrinseco:**

A differenza delle reti neurali classiche, l'Encoder non "legge" da sinistra a destra; richiede parametri aggiuntivi (Positional Encoding) per capire la sequenza.

- **Necessità di Grandi Dataset:**

Per essere efficace, un Encoder richiede una quantità massiccia di dati per evitare l'overfitting (apprendimento a memoria).

- **Difficoltà di Ottimizzazione:**

Bilanciare correttamente il numero di teste d'attenzione e la profondità dei layer richiede numerosi tentativi e competenze avanzate.


Svantaggi

L'implementazione di questi modelli comporta oneri significativi su tre fronti. Economicamente, l'acquisto di hardware dedicato (GPU) richiede investimenti di migliaia di euro. Sotto il profilo temporale, l'addestramento dei modelli più vasti può richiedere settimane di calcoli ininterrotti. Infine, l'impatto ambientale è critico: l'enorme consumo energetico necessario per il funzionamento e il raffreddamento dei server solleva importanti questioni di sostenibilità.

Costi

Summary

- Encoder models are really powerful and fast. They are great because they understand the context of every word perfectly.
- However, there are some downsides: they need a lot of memory and very expensive hardware to work. In conclusion, these models are amazing, but they cost a lot of money and use a lot of energy.



Bibliografia

✓ **Fondamenti dell'Architettura**

- *The Transformer: Attention Is All You Need - Interactive* (Michael Brenndoerfer)

✓ **Scalabilità e Prestazioni (Scaling Laws)**

- *Chinchilla Scaling Laws: Compute-Optimal Training* - Michael Brenndoerfer

✓ **Hardware e Infrastruttura**

- *NVIDIA H100 Deep Dive: Specs, Pricing, and Where to Run It (2026)* - Fluence

✓ **Sostenibilità e Impatto Ambientale**

- *Energy demand from AI* - IEA (International Energy Agency)

